


Ciência dos dados

Professor: Dr. Marcelo Diaz




**“Quando estamos vendendo é Inteligencia artificial,
quando estamos contratando é Aprendizado de maquina
e quando implementamos é Regressão logística”**


(Adaptado de Hui Lin and Ming Li, 2023)

Principais áreas do conhecimento


Estatística





Matemática




Ciência da Computação



Ciência



Principais áreas do conhecimento



O que é Ciência dos Dados?

Princípios da Ciência:

✗ Racionalidade

✗ Objetividade:



- Experimentação / Validação

- Debate Critico


O que é Ciência dos Dados?

Ciência é Construção do conhecimento


Dados são uma representação fatural



“Ciência dos dados” no Google Trends




Quando começou?




1805, Gauss: método dos mínimos quadrados

1936, Fisher: análise de discricionalidade linear

1970, Nelder and Wedderburn: Modelo Linear Generalizado





Quando começou?



1984, Breiman: CART (árvores de classificação e regressão)



2001, Breiman: Random Forest



2006, Geoffrey Hinton: Redes Neurais Profundas (Deep Learning)

<https://www.youtube.com/watch?v=Suevq-kZdlw&t=100s>

[illegible]

A collection of hand-drawn icons representing various fields of science and technology. The icons include: a beaker with bubbles, a calculator, an atom, a cell, a microorganism, a graph with a bell curve, a globe, a molecular structure, a rocket, a lightbulb, a plug, a book, a pi symbol, a sine wave, a pill, a microscope, a hexagonal molecule, a brain, a DNA helix, a water molecule (H2O), a magnet, a planet with a ring, a star, a square root symbol (√2), a lightbulb, a book, a pi symbol, an apple, a test tube with a plant, a globe, a molecular structure, a rocket, a cell, a microorganism, a graph with a bell curve, an atom, a calculator, and a beaker with bubbles.



Engenharia de dados



Analise de Dados



Modelagem

Engenharia

Ambiente de dados:




- ✗ Infraestrutura
- ✗ Gerencia do fluxo
- ✗ Data Warehouse, SQL, cluster hadoop e Sparks

Gestão de dados:



- ✗ Coleta: API, webscreping, logs, Apache Kafka, google forms, xml
- ✗ Padronização
- ✗ Qualidade
- ✗ Documentação

Processo:



- ✗ Automatização, ETL, Pré-processamento
- ✗ Conhecimento da Pipeline
- ✗ KDD (Knowledge Discovery in Data bases)
- ✗ CRISP-DM (Cross-Industry Standard Process for Data Mining)

Analise

Conhecer o contexto:



- ✗ Conhecimento a cerca do objeto de analise
- ✗ Comercial / Industrial
- ✗ Pontos Criticos, Custo, Tempo...

Analise exploratória:



- ✗ Resumo estatístico (media, desvio padrão...)
- ✗ Analise baseada em Correlação
- ✗ Extrair ideias
- ✗ Indicar o caminho a qual se aprofundar

Narrativa:



- ✗ Storytelling
- ✗ Simplicidade
- ✗ Relatório amigável



Modelagem

Predição:




- ✗ Prever com base no que aconteceu
- ✗ Aprendizado de maquina
- ✗ Sem preocupação do porque (Modelos caixa-preta)

Explicação:



- ✗ Encontrar padrões que não são visíveis na análise básica (AED)
- ✗ Experimentação
- ✗ Teste A/B

Inferência:




- ✗ Experimentos complexos
- ✗ Inviabilidade de testes com a população
- ✗ Amostras
- ✗ Intervalos de confiança
- ✗ Ex: Políticas publicas, vacinas



Papel	Habilidades
Engenheiro de infraestrutura de dados	Ir, Python, AWS/Google Cloud/Azure, logstash, Kafka e Hadoop
Engenheiro de dados	spark/scala, python, SQL, AWS/Google Cloud/Azure, Modelagem de dados
Engenheiro de BI	Tableau/looker/Mode, etc., visualização de dados, SQL, Python
Analista de informações	SQL, estatística básica, visualização de dados
Cientista de dados	R/Python, SQL, estatística aplicada básica, visualização de dados, design experimental
Pesquisa científica	R/Python, estatística avançada, design experimental, ML, histórico de pesquisa, publicações, contribuições para conferências, algoritmos
Cientista aplicado	Design de algoritmo de ML, geralmente com expectativa de habilidades fundamentais de engenharia de software
Engenheiro de aprendizagem de máquina	Conjunto de habilidades de engenharia de software mais avançado, algoritmos, design de algoritmo de aprendizado de máquina, design de sistema

Ciclo na Ciência dos Dados



-
- The diagram illustrates the relationship between variables, observations, and values in a dataset. It consists of three parts:
- Variables:** A table with 5 columns: country, year, cases, population, and a missing value (NA). The rows represent different countries: Afghanistan, Algeria, Brazil, China, and the United States. The label "variables" is centered below the table.
 - Observations:** A table with 5 columns: country, year, cases, population, and a missing value (NA). The rows represent different years: 2017, 2018, 2019, 2020, and 2021. The label "observations" is centered below the table.
 - Values:** A table with 5 columns: country, year, cases, population, and a missing value (NA). The rows represent different values: 171, 182, 153, 125, and 108. The label "values" is centered below the table.
- Arrows indicate the relationships between the tables:
- Vertical double-headed arrows connect the "country" and "year" columns in the "variables" table to the "country" and "year" columns in the "observations" table.
 - Horizontal double-headed arrows connect the "cases" and "population" columns in the "variables" table to the "cases" and "population" columns in the "observations" table.
 - Vertical double-headed arrows connect the "cases" and "population" columns in the "observations" table to the "cases" and "population" columns in the "values" table.






Diagram illustrating the relative volume of data processing versus preprocessing. The visible tip of the iceberg represents 'Processamento' (Processing), while the much larger submerged portion represents 'Pré-processamento' (Preprocessing).

Atividades na Ciência dos Dados: Processamento




Descritivas (AED):

- ✗ Analítico
- ✗ Resumo estatístico (media, desvio padrão, variância...)
- ✗ Visualização básica (dispersão, frequência, box-plot)
- ✗ Respostas superficiais e aparentes baseadas em correlações



Comparação (AED):

- ✗ identificação e análise entre indivíduos ou entre os grupos
- ✗ Resumo estatístico (media, desvio padrão, variância, covariância...)
- ✗ Regressões lineares
- ✗ Visualização básica (dispersão, frequência, box-plot)
- ✗ Testes estatísticos (ANOVA. QUI-QUADRADO)




Atividades na Ciência dos Dados: Processamento



Agrupamento (AED):

- ✗ Analítico/Modelagem
- ✗ Identificação de grupos
- ✗ Clustering (K-Means)
- ✗ Ex: Quantos são os tipos de clientes e como se diferenciam



Classificação:

- ✗ Modelagem
- ✗ Baseado em Rótulos (classes)
- ✗ Prever rótulos de uma nova observação (Random Forest)
- ✗ Exemplo:
 - Spam ou não
 - Retorno de cliente





Atividades na Ciência dos Dados: Processamento



Como a minha previsão interage com as regras de negocio (prescritiva)

Regressão:


- ✗ Modelagem
- ✗ Resposta Numérica
- ✗ Maior variedade de modelos (GLM, Redes neurais, Arvores de decisão)
- ✗ Rotineiro
- ✗ Exemplos:
 - Quanto custa?
 - Faturamento?
 - Qual sera a Temperatura?



Atividades na Ciência dos Dados: Entrega



Interfaces (Dashboards)



rmarkdown (html, PDF)



API



RoadMap



Conhecimento a ser desenvolvidos

Promover o Conhecimento do domínio e colaboração com outras disciplinas e a sociedade



Estimular o pensamento crítico analítico



Desenvolver Habilidades de programação e gestão de dados



Aprimorar as habilidades de comunicação para apresentação dos resultados




Problemas

- ✗ Não compreensão do problema
- ✗ Conhecimento limitado do tema
- ✗ Prometer demais (expectativas irreais)
- ✗ Cronograma (metodologia ágeis)
- ✗ Expectativas de qualidade e volume de dados
- ✗ Modelar com dados não representativos
- ✗ Overfitting e modelo complexos
- ✗ Falha ao escalar e monitorar modelagem em tempo real
- ✗ **Saber desistir**




Fluxograma Prático Modelagem




<https://parsnip.tidymodels.org/reference/index.html>
<https://www.tidymodels.org/find/parsnip/>

Fluxograma Pratico Modelagem





Atividade



Atividade

Análise de frequência (Probabilidade)



Referencias

