

Sistemas de Informação | AMF
Inteligência Artificial II
31 de agosto de 2026

Aula 4 - Pré-processamento de dados, Engenharia de atributos


Rhauani Fazul
rhauani.fazul@amf.edu.br

Agenda

- Pré-processamento de dados
- Atividade prática - Parte 1
- Engenharia de atributos
- Atividade prática - Parte 2

Objetivo

Exploratory Data Analysis (EDA) / Análise Exploratória de Dados



Pré-processamento de dados

Modelos tradicionais de ML:

- **Entrada estruturada:** variáveis numéricas, categóricas, tabulares.
- Pré-processamento crucial: normalização, limpeza de *outliers*, balanceamento de classes.
- Impacto direto: **dados ruins** → **modelo fraco** (viés, baixa acurácia, *overfitting*).
- Exemplo: um simples erro de digitação em um dataset de crédito (“inadimplente/não inadimplente”), pode fazer com que o classificador aprenda padrões distorcidos.

Pré-processamento de dados

IA generativa:

- Dados de treinamento massivos: corpus de texto, imagem, áudio.
- **Ruído mais difícil de rastrear:** vieses, estereótipos, informações desatualizadas embutidas nos dados.
- Impacto ampliado: não só reduz precisão, mas gera outputs plausíveis e convincentes, porém errados (“**alucinações**”).
- Contexto de prompt: instruções mal formuladas = saída incoerente ou inútil.
- **Escala do problema:** quanto maior e menos curado o dataset, mais difícil garantir consistência.

Pré-processamento de dados

Principais técnicas:

- **Limpeza de dados:** tratamento de valores ausentes, duplicados, inconsistências.
- **Normalização e padronização:** escalonamento de variáveis (ex.: MinMaxScaler, StandardScaler).
- **Codificação de variáveis categóricas:**
 - Label encoding
 - One-hot encoding
- **Divisão treino e teste/validação:** 80/20, por exemplo.

Pré-processamento de dados

Label encoding: cada categoria recebe um número inteiro.

Cor: [Vermelho, Azul, Verde]

→ [0, 1, 2]

Vantagem: simples e ocupa menos memória.

Problema: o modelo pode interpretar que existe uma ordem (ex.: "Azul < Verde < Vermelho"), o que muitas vezes não faz sentido.

Usado em: algoritmos baseados em árvores (decision tree, random forest, XGBoost), que não se confundem com essa "ordem".

Pré-processamento de dados

One-hot encoding: cria uma coluna binária (0/1) para cada categoria.

Cor: [Vermelho, Azul, Verde]

→ Vermelho: [1,0,0], Azul: [0,1,0], Verde: [0,0,1]

One-hot clássico: uma única categoria ativa ([0,1,0]).

Multi-hot encoding: várias categorias podem ser ativas ao mesmo tempo ([1,1,0]).

Vantagem: evita interpretação errada de ordem.

Problema: aumenta muito a dimensionalidade (se tiver 100 categorias, gera 100 colunas!).

Usado em: modelos lineares, redes neurais, SVM, etc.

Agenda

- Pré-processamento de dados
- Atividade prática - Parte 1
- Engenharia de atributos
- Atividade prática - Parte 2

Atividade: Pré-processamento de dados

Dataset: Titanic (dados observacionais)

informações coletadas ao registrar um fenômeno, evento ou comportamento à medida que ocorre naturalmente, sem intervenção ou manipulação por parte do pesquisador

Cada linha representa um passageiro. Algumas colunas típicas:

- **Survived** (0 = não sobreviveu, 1 = sobreviveu) → *variável alvo*
- **Pclass** (classe do ticket: 1^a, 2^a, 3^a)
- **Name** (nome do passageiro)
- **Sex** (sexo)
- **Age** (idade)
- **SibSp** (nº de irmãos/cônjuges a bordo)
- **Parch** (nº de pais/filhos a bordo)
- **Ticket** (nº do bilhete)
- **Fare** (valor da passagem)
- **Cabin** (nº da cabine)
- **Embarked** (porto de embarque: C = Cherbourg, Q = Queenstown, S = Southampton)

Dica: transformem em um dataframe (pandas)

Grupos até 3 alunos!

Atividade: Pré-processamento de dados

Podem baixar o dataset (csv) e realizar a leitura normal em Python ou:

```
import seaborn as sns
```

biblioteca de visualização de dados em Python, construída em cima do matplotlib e integrada com pandas

```
# Dataset Titanic incluso no seaborn
```

```
titanic = sns.load_dataset("titanic")
```

Atividade: Pré-processamento de dados

Exploração inicial

Ver valores nulos (ex.: Age, Cabin, Embarked têm muitos).

Distribuições: idade, tarifa, classes sociais.


Atividade: Pré-processamento de dados

Tratamento de valores faltantes

Age → preencher com média, mediana ou criar categorias de idade.

Embarked → preencher com moda (porto mais comum).

Cabin → pode ser descartado (muitos nulos) ou transformado em "tem/não tem informação".



Atividade: Pré-processamento de dados

Codificação de variáveis categóricas

Sex → transformar em 0/1 (Label Encoding).

Embarked → One-hot encoding (C, Q, S).

Atividade: Pré-processamento de dados

Normalização/escalonamento

Fare e **Age** → normalizar/*standardizar* para algoritmos sensíveis a escala (KNN, SVM).

Normalização → restringe os dados a um intervalo (ex.: [0,1]).

Escalonamento (no sentido de padronização) → ajusta média e variância (média 0, desvio 1).

Se a variável “altura” tinha:

- média = 170 cm
- desvio = 10 cm
- valor x = 180 cm

Então: $Z = (180 - 170) / 10 = 1$

→ Essa pessoa está **1 desvio-padrão acima da média**.

Normalization

Standardization

$$X_{new} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

$$X' = \frac{X - \text{Mean}}{\text{Standard deviation}}$$

Agenda

- Pré-processamento de dados
- Atividade prática - Parte 1
- Engenharia de atributos
- Atividade prática - Parte 2


Engenharia de atributos

Pré-processamento: deixar os dados “prontos” para o modelo.

Engenharia de atributos: deixar os dados “mais inteligentes” para o modelo.

- **Objetivo:** criar e transformar variáveis para aumentar a capacidade do modelo de capturar padrões.
- É mais criativo e próximo da **inteligência de domínio**.

Engenharia de atributos



Engenharia de atributos

- **Criação de variáveis derivadas**
 - **Combinações** ou **transformações** de atributos existentes.

Exemplos:

- Interações: idade $\times$ renda $\rightarrow$ poder de compra.
- Polinomiais: x^2 , x^3 para capturar não-linearidades.
- Transformações: $\log(\text{salário})$ para reduzir assimetria.

Engenharia de atributos

- **Codificação semântica / representações**
 - Incorporar **conhecimento de domínio**.

Exemplos:

"data de nascimento" → converter em "idade" ou "faixa etária".

"endereço" → latitude/longitude ou região.

Engenharia de atributos

- **Redução de dimensionalidade**
 - Simplificar mantendo a informação mais relevante.
 - PCA, t-SNE, UMAP.
 - Útil em datasets com muitas variáveis correlacionadas.

Engenharia de atributos

- **Seleção de atributos**

- **Escolher os mais relevantes para o modelo** → evitar *overfitting*.
- *Filter*: testes estatísticos (correlação, qui-quadrado).
- *Wrapper*: usa modelos iterativos (ex.: Recursive Feature Elimination).
- *Embedded*: seleção feita pelo próprio algoritmo (ex.: LASSO, árvore de decisão, Random Forest).

Engenharia de atributos

- **Discretização (*data binning*)**

- Transformar variáveis contínuas em categorias.
- Ex.: Idade → jovem, adulto, idoso.
- Útil para simplificação e interpretabilidade.

- **Agrupamentos (*clustering* como feature)**

- Criar nova variável com base em clusters encontrados.
- Ex.: Clientes → “segmento 1, 2, 3” obtido via K-means.

Agenda

- Pré-processamento de dados
- Atividade prática - Parte 1
- Engenharia de atributos
- Atividade prática - Parte 2

Atividade: Engenharia de atributos

Criar novas features no dataset do Titanic:

familySize = SibSp + Parch + 1 (quem estava com família tinha mais chance?).

farePerPerson = fare / familySize

isAlone (1 = sozinho, 0 = com família).

isChild (age < 12)

(e mais... sejam criativos!)

- Depois vamos testar se os novos atributos melhoram o desempenho do modelo!

Próxima aula...

- Modelos tabulares e boosting.
 - Intuição sobre outros algoritmos (Random forest, Boosting).
- Continuação da prática sobre o dataset do Titanic.
- Passagem do trabalho prático T1.